ru:corner

Разметка именованных сущностей и кореференции в brat

Анастасия Никифорова Сергей Терновых steysie@gmail.com fostroll@gmail.com

Денис КиреевКонстантин Ремизовdkireev.71@gmail.commr.enslin@mail.ru

Содержание

1	Оби	цая информация о разметке в brat	1
	1.1	Начало работы. Авторизация	1
	1.2	Выбор текста из коллекции	2
	1.3	Выделение и разметка текста	2
	1.4	Связи между размеченными упоминаниями	3
	1.5	Изменение и удаление меток	4
	1.6	Нерелевантные тексты	4
	1.7	Поиск незнакомых терминов в Google и Википедии	5
	1.8	Комментарии к сущностям	5
2	Разі	метка именованных сущностей в brat	5
	2.1	Алиасы названий сущностей в интерфейсе	6
	2.2	Вложенные и пересекающиеся сущности	6
	2.3	Атрибуты типов сущностей	10
	2.4	Различия подтипов сущностей Time и Date	11
	2.5	Некоторые правила вложенности и разделения сущностей	11
		2.5.1 Про Facility, Event и Service	12
		2.5.2 Про Date в Facility и Event	12
		2.5.3 Про Event в Date: Absolute и Period	13
		2.5.4 Про сочетания Family с Person и Person Property	13
3	Разі	метка кореференции в brat	15
4	Отд	ельные случаи	17
	4.1	Уточняющие прилагательные	17
	4.2	Уточняющие именные группы	17
	4.3	Продукт, серия, уникальное название – как быть?	18
	4.4	Предлоги	18
	4.5	Знаки препинания	18
	4.6	Кавычки	19
	4.7	Временные выражения с неопределенными границами	20
	4.8	Одиночные именованные сущности и анафора	20
	4.9	Numeric: Quantity vs. Cardinal в случае эллипсиса	21
	4.10	Выделение сущности, разбитой на две строки	21
	4.11	Возможные ошибки и предупреждения	22
Пј	рило	жение A Changelog	24

1 Общая информация о разметке в brat

brat — инструмент для разметки именованных сущностей (и других текстовых интервалов) и связей между ними. В ru:corner brat используется для разметки именованных сущностей и кореференции.

Окно разметки в brat изображено на Рисунке 1.

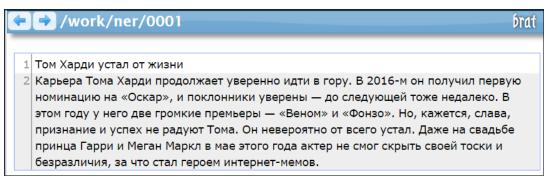


Рис. 1: Пример окна разметки в brat

<u>Bажно!</u> Для разметки текстов в **brat** необходимо установить и использовать браузер **Mozilla Firefox**. Другие браузеры (Chrome, Opera и др.) склонны вызывать ошибки разметки, описанные в Разделе 4.11.

1.1 Начало работы. Авторизация

Разметка в **brat** доступна только для авторизованных пользователей. Чтобы авторизоваться, наведите курсор к шапке страницы, над текстом. В появшейся строке выберите **Login** (Рисунок 2).

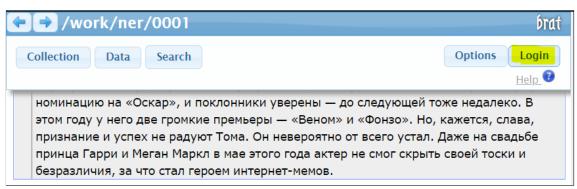


Рис. 2: Авторизация в brat

В появившемся окне введите логин и пароль и нажинте **ОК** (Рисунок 3). После успешной авторизации внизу страницы появится приветственное сообщение.

После входа в аккаунт можно выбрать текст из коллекции и приступать к разметке именованных сущностей или кореференции.



Рис. 3: Окно авторизации

1.2 Выбор текста из коллекции

Документы для разметки являются частью коллекции (Collections). Для выбора первого текста разметки, пройдите в нужную директорию и выберите файл двойным нажатием (Рисунок 4). Откроется окно с текстом как на Рисунке 1.

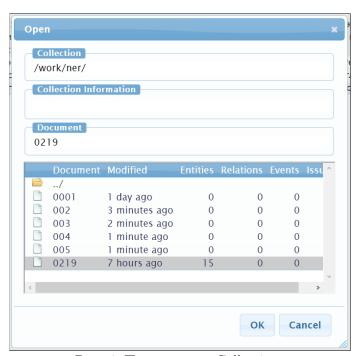


Рис. 4: Пример окна Collections

1.3 Выделение и разметка текста

Для того, чтобы разметить отрезок текста как именную сущность или упоминание, выделите курсором нужное слово или фразу от первой буквы первого слова, до последней буквы последнего слова. Единичные слова можно выделять, нажав на них дважды левой кнопкой мыши.

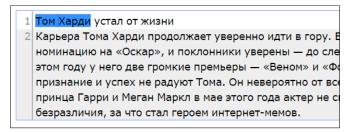


Рис. 5: Пример выделенного отрезка текста

Как только текст выделен, появится окно выбора типа сущности (Рисунок 6). Подробнее о видах меток отдельно для разметки именованных сущностей и кореференции можно прочитать в разделах 2 и 3.

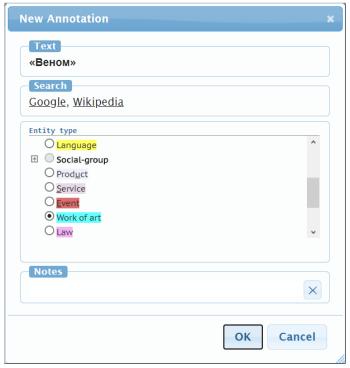


Рис. 6: Пример окна выбора метки именованной сущности

В окне выбора типов сущностей выберите подходящую метку и нажмите ${\sf Enter}$ или щелкните курсором по ${\sf OK}$.

Когда весь текст размечен, нажмите клавишу \to или кликните на кнопку \Longrightarrow в левом верхнем углу brat.

1.4 Связи между размеченными упоминаниями

При разметке кореференции необходимо попарно связать размеченные упоминания стрелкой и выбрать тип связи.

Для образования связи, нажмите на метку одного из упоминаний (часто – зависимый член), как на Рисунке 7 и перетащите появившуюся стрелку на второе упоминание, как на Рисунке 8.

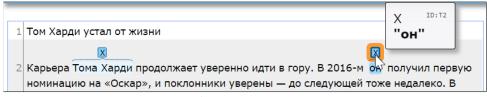


Рис. 7: Шаг 1. Выбор метки одного из упоминаний

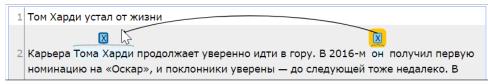


Рис. 8: Шаг 2. Связывание кореферентной группы

Когда упоминания связаны, появится окно выбора типа связи. Подробнее о видах кореферентных связей можно прочитать в разделе 3.

После выбора тип связи отобразится на стрелке (Рисунок 9).

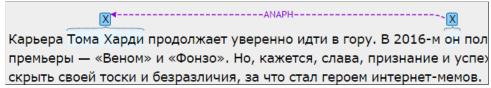


Рис. 9: Шаг 3. Выбор связи

1.5 Изменение и удаление меток

Чтобы изменить или удалить метку сущностей (в случае ошибочного выбора метки и т. п.), дважды щелкните на название метки. Появится окно выбора типа сущностей (Рисунок 10).

Для изменения типа сущности, выберите другую метку из списка.

Для изменения выделенного диапазона, нажмите **Move** и заново выделите сущность.

Для удаления метки, нажмите Delete.

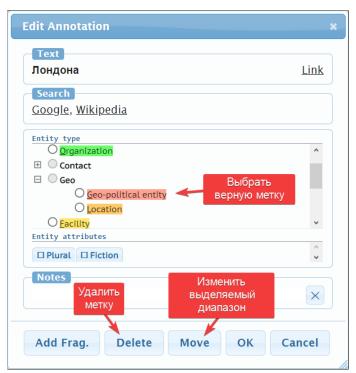


Рис. 10: Изменение и удаление меток именованных сущностей

1.6 Нерелевантные тексты

В коллекции могут попадаться тексты, в которых преобладают другие языки, которые также используют кириллицу – например, украинский или белорусский. Также могут встречаться тексты, преимущественно состоящие из стихов.

В таких текстах необходимо отметить только первое слово специальным тегом [!!! INVALID DOCUMENT !!!]. Весь остальной текст следует оставить неразмеченным, как показано на Рисунке 11.

Верховна Рада України, ґрунтуючись на Декларації про державний суверенітет України від 16 липня 1990 року та схваленому Всеукраїнським референдумом 1 грудня 1991 року Акті проголошення незалежності України від 24 серпня 1991 року, якими було відновлено незалежну національну державність України

Рис. 11: Пример разметки нерелевантного текста

Если в тексте преобладает русский язык, но встречаются фразы на других языках, такой текст размечается как обычно.

1.7 Поиск незнакомых терминов в Google и Википедии

Чтобы найти значение незнакомых слов в Google и в Википедии, выделите нужный отрезок текста. В появившемся окне в разделе **Search** нажмите на **Google** или **Wikipedia** (Рисунок 12).

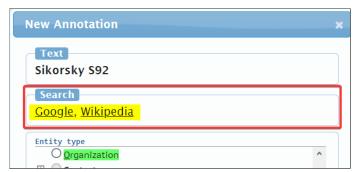


Рис. 12: Поиск незнакомых терминов в Google и Wikipedia

1.8 Комментарии к сущностям

Если вы не уверены, правильно ли выделена сущность, можно оставить короткий комментарий в окне выбора метки в разделе **Notes**. Чтобы удалить комментарий, нажмите на крестик справа в поле **Notes**.

2 Разметка именованных сущностей в brat

Для разметки именованных сущностей в ru:corner предусмотрено 44 различных типа сущностей. Подробное описание сущностей с примерами приведено ниже в Таблице 1.

Некоторые сущности могут иметь дополнительные атрибуты, один или несколько из следующих категорий: Plural, Fiction, Unconsciuos, Department, Media, Citizenship, Project, Trademark. Подробнее об атрибутах – в Разделе 2.3.

Для наиболее частотных типов сущностей предусмотрены горячие клавиши (колонка Hotkey в Таблице 1). При открытом окне выбора типа именованных сущностей нажмите подходящую горячую клавишу и нажмите Enter. Над выделенным упоминанием появится нужный тип сущности.

2.1 Алиасы названий сущностей в интерфейсе

В зависимости от длины выделенной фразы, в интерфейсе могут использоваться укороченные варианты одного и того же типа сущности, как показано на Рисунке 13.

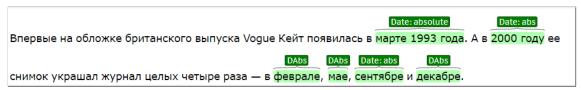


Рис. 13: Примеры алиасов сущности Date: absolute

2.2 Вложенные и пересекающиеся сущности

Именованные сущности могут быть составными, то есть могут включать в себя вложенные сущности (а-ля "матрёшка"). Примеры разметки с учетом вложенности на Рисунке 14.

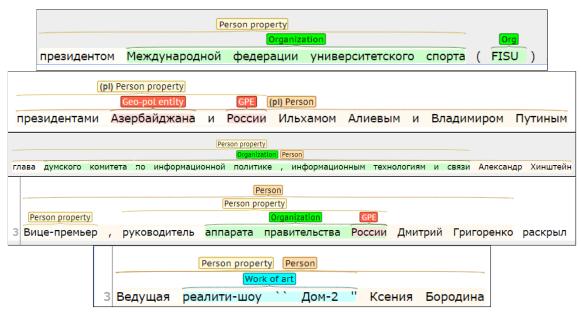


Рис. 14: Примеры пересекающихся и вложенных сущностей

Любые типы сущностей могут быть составными. Чаще других составными оказываются сущности Person, которые часто включают в себя сущности Person Property, GPE и т. д.

Примечание. Пересекающимися могут быть только сущности из категории Quantity (количество). Например, "{шестерых [членов} экипажа]"

Таблица 1. Типы сущностей, их описания и примеры

Категория	Тип сущности	Атрибуты	Hotkey	Описание типа сущности	Пример
!!! INVALID	DOCUMENT !!!			Любые стихи и тексты, написанные преимущественно не на русском языке (украинский, белорусский и др.)	Отметьте первое слово в нерелевантном тексте
		□ Plural □ Fiction □ Unconscious [default]	Р	Имя или псевдоним реального человека. В качестве Person могут употребляться не только имена собственные, но и другие устойчивые выражения, зачастую имя+свойство, если это выражение часто используется в СМИ, кино или литературе для идентификации этого известного человека или персонажа.	Смирнов Иван Петрович, Сан Саныч, Машуня, Андрюха, Петр I, Бейонсе, Роберт Дауни Младший, Шакил О'Нил, Шекспир, Пушкин, Моцарт, 50 cent, Моргенштерн, королева Елизавета, Президент Путин, товарищ Сталин, дорогой Леонид Ильич, президент Борис Ельцин
	orcon	☑ Plural		Имена нескольких людей в одной сущности	Павел и Марина Смирновы, Дэвид и Виктория Бэкхам
_	<u>P</u> erson			Имена или псевдонимы вымышленных персонажей, богов (кино, литература, комиксы, религия, мифология и т. п.)	Евгений Онегин, Губка Боб, попугай Кеша, Энакин Скайуокер, Иисус Христос, Будда, кот Матроскин, Мальчик который выжил, Тот-чье- имя-нельзя-называть
				Любые имена, которыми люди называют неразумные уникальные объекты: животные, техника, корабли и т. п. (включая тип объекта, если он указан, напр., "корабль")	Барсик, Белка, Стрелка, Несси (лох-несское чудовище), броненосец "Потемкин", корабль "Сметливый", баркас "Fishizzle", "Союз МС-16", эсминец Джон Маккейн, корабль Орион, ледокол "Арктика"
Pe <u>r</u> so	n property	□ Plural □ Fiction [default]	R	Чин, звание, титул, должность, профессия и т. п.	генерал-майор, королева, канцлер, сварщик, менеджер, президент, инженеры, разработчики, депутаты, ученые, исследователи, срочник, заключенные, задержанные, папа римский
		☑ Plural		Несколько Property в одной сущности	"главы России, Азейбарджана и Армении"
		☑ Fiction		Вымышленные титулы/профессии и т. п.	профессор защиты от темных искусств, штурмовик Первого Ордена
			0	Компании, агентства, радиостанции, институты, политические партии и т. п., имеющие орг. структуру	Ростелеком, Amazon, ПАО "Газпром", партия "Единая Россия", РПЦ, компания Орифлейм, Белорусская оппозиция, турецкая армия
<u>O</u> rga	nization	☑ Plural		Несколько организаций или отделов в рамках одной сущности	Норильский и Алтайский горнодобывающие заводы, финансовый и юридический отделы, Московская и Екатеринбургская епархии
		☑ Fiction		Вымышленные организации (кино, литература и т. п.)	галактический сенат, Stark Industries, Спектр, школа волшебства Хогвартс
		☑ Department		Отделы внутри организаций	IT-департамент, отдел кадров, совет директоров, топ-менеджмент
		☑ Media		СМИ: издательства, журналы, газеты и т.п., включая печатные издания	издательство ЭКСМО, Эхо Москвы, Лента.ру, Cosmopolitan, АиФ, Первый канал
	<u>A</u> ddress		А	Адрес местоположения, зачастую - город, улица, дом, квартира, индекс	123456, Москва, Тверская улица, дом 10, строение 2; адрес: ул. Ленина, д. 5 +7 (123) 456-78-90, тел. 81234567890, телефон
	P <u>h</u> one		Н	Номер телефона	+/ (123) 456-78-90, Тел. 81234567890, Телефон 44-22-33
Contact	E <u>m</u> ail		М	Адрес электронной почты	name@wsite.com, email: user@edu.site.org
	<u>W</u> eb address			Ссылка на веб-страницу	https://website.com/info/, google.com
	Other-contact			Имя пользователя, профиль в instagram и т.п.	@someusername, telegram: @bestname, tg username, instagram: followme
<u> </u>	vent	□ Plural [default]	E	Ураганы, сражения, войны, спортивные состязания, праздники и т. п. (не одиночные слова типа "концерт", "церемония" и т. д.)	Новый год, ураган Катрина, Чемпионат мира по футболу, Брусиловский прорыв, пандемия коронавируса, предизентские выборы в США, бой Хабиба и Коннора, концерт Баскова и Киркорова (одно мероприятие)
		☑ Plural		 Несколько Event в рамках одной сущности	ураганы Катрина и Рита, концерты Баскова и Киркорова (разные мероприятия)
	<u>G</u> eo-political entity (GPE)	□ Plural □ Fiction [default]	G	Географическая зона, имеющая политическую структуру + космические станции (GPE)	Ростов-на-Дону, Швейцария, Ближний Восток, г. Москва, СНГ, СССР, Катманду, деревня Кунцево, Алтуфьевский район, столица (если понятно, что Москва)
		☑ Plural		Несколько GPE	Московская и Ленинградская области
Geo		☑ Fiction		Вымышленная географическая зона	Атлантида, Хогвартс, Нарния, Вестерос, Средиземье, Готэм-сити, Асгард
		□ Plural □ Fiction [default]	L	Места, природные: горные цепи, водоемы + планеты, галактики, созвездия, кометы и т. п.	озеро Байкал, Волга, р. Нева, оз. Чад, Гималаи, Эверест, Земля, Луна, Марс, Астероид 501647, Млечный путь, естественный спутник Земли
	l a satte ::	☑ Plural		Несколько Location	реки Тигр и Евфрат
	<u>L</u> ocation	☑ Fiction		Вымышленные 7места	Мглистые горы, Андуин, река Яруга

Таблица 1. Типы сущностей, их описания и примеры

Категория	Тип сущности	Атрибуты	Hotkey	Описание типа сущности	Пример
<u>F</u> acility		□ Plural □ Fiction [default]	F	Достопримечательности, здания, аэропорты, шоссе, парки, мосты, улицы, площади, переулки и т. п.	памятник Ильичу, Внуково, Трасса М4, ТРЦ "Авиапарк", Дворцовый мост, Арбат, Трехсвятская улица, проспект Ленина
		☑ Plural		Несколько Facility	трассы М4 и М5
		☑ Fiction		Вымышленные Facility (кино, литература и т. п.)	Замок Саурона, Замок Дарта Вейдера, Галактический рынок
Language		□ Plural □ Fiction [default]		Языки естественные или искусственные (не из кино/литературы)	русский язык, итальянский, иврит, хинди, язык йоруба, урду, эсперанто, северные диалекты русского языка
		☑ Plural		Несколько объектов Language в рамках одной сущности	южные и восточные диалекты, тюркские и финноугорские языки, говоры и наречия русского языка
		☑ Fiction		Вымышленные языки (кино, литература)	клингон, на'ви, дотракийский, новояз
		☐ Citizenship ☐ Plural [default]		Принадлежность к нации по происхождению, рождению или иным образом	русские, итальянец, гречанка, папуасы, финны, афроамериканцы, кореец, индус, армянского происхождения
		☑ Citizenship		Гражданство какой-либо страны	граждане РФ, гражданка Эстонии, жители Китая, американцы
	Nationality	☑ Plural		Несколько разных объектов Nationality в одной сущности	Граждане Грузии и Армении, жители Северной и Южной Кореи
	Family		Υ	Обозначения родственных связей	мать, брат, старший сын, сводная сестра, двоюродная тетя, брат жены, семья, род
		□ Plural [default]		Принадлежность к определенной религии	православные, католик, старообрядцы, амиши, шииты, буддист, пастафарианцы
Social-	Religious group	☑ Plural		Несколько разных религиозных групп в одной сущности	православные, католические и протестантские христиане
group	Political group	□ Plural [default]		Принадлежность к политической группе	республиканцы, члены партии "Единая Россия", национал-демократы, коммунисты, члены партии «Свобода»
		☑ Plural		Несколько политических групп в одной сущности	члены КПРФ и ЛДПР, члены партий Единая Россия и Яблоко
		□ Plural □ Fiction [default]		Другие социальные группы, члены которых имеют что-то общее	безработные, руководители, веганы, гангстеры, новые русские, готы, геи, бомжи, преступник, избиратели, бюджетники, поклонники, эксперты
		☑ Plural		Несколько разных групп в одной сущности	представители готов и эмо, участники клубов рукоделия и гончарства
	Other group	☑ Fiction		Вымышленные социальные группы	хоббиты, эльфы, орки, джедаи, члены банды "Железные рукава"
		□ Plural □ Project □ Trademark [default]	U	Электроника, автомобили, оружие, продукты питания, одежда, техника, серии водных/космических судов и т. п. (конкретные продукты с указанием серии/производителя)	пылесос Dyson, диваны Икеа, Range Rover, Айфон, Орион чокопай, пистолет Макарова, АК-47, косметика Орифлейм, платье бренда Виктория Бекхам, танк ТЗ4, космические корабли "Союз", Катюша (оружие)
Pi	rod <u>u</u> ct	☑ Plural		Несколько продуктовых сущностей в рамках одной	диваны Икеа и Hoff, пылесосы Dyson и Xiaomi, косметика Эйвон и Орифлейм
		☑ Project		Проекты, программы (государственные, научные, космические и т. п.)	мегасаенс-проект NICA, нацпроект "Наука", программа обмена студентами Erasmus +, программа «Вояджер»
		☑ Trademark		Бренд, запатентованная технология, торговая марка продукта (не в значении "компания/организация")	Dyson, Apple, Орифлейм, Виктория Бекхам, Шанель, Tesla, технология ProMotion
<u>S</u> ervice		□ Plural □ Media [default]	S	Различные предприятия, приложения и технологии предоставления услуг, онлайн-платформы	чистка обуви, ремонт ноутбуков, доставка еды, телефония, Яндекс.Еда, Telegram, TikTok, YouTube, Facebook
		☑ Plural		Несколько сервисов в одной сущности	услуги прачечной и химчистки, услуги телефонии и интернета
		Media		Аккаунты, каналы, страницы, сайты, сообщества и т. П. (главный признак - они могут публиковать контент и имеют уникальное имя)	Телеграмм-канал ``IT юмор", страница Ольги Бузовой, сайт ООН, твиттер-аккаунт Трампа, страница в Facebook
Work of art				Названия книг, песен, картин, фильмов, ТВ шоу, сериалов и т. п.	Властелин колец, Мона Лиза, "Белые розы", Черный квадрат Малевича
Law		□ Plural [default]		Нормативно-правовые акты	Конституция, статья 20.6.1 КоАП, Закон о защите прав потребителей
		☑ Plural		Несколько Law в одной сущности	п. 2 статьи 228 и пп. 3 и 4 статьи 230 УК РФ

Таблица 1. Типы сущностей, их описания и примеры

Категория	Тип сущности	Атрибуты	Hotkey	Описание типа сущности	Пример
	<u>D</u> ate: absolute		D	Явная дата (когда? какой день/месяц/год?), включая упоминания праздников	20 октября 2000 г., пятое августа, январь 2021 года, 2020, в марте, "в среду, 2 марта", после майских праздников
Date	Date: relative			Относительная дата, включая конечные предлоги (когда относительно другой даты?)	через сутки, три дня назад, прошлый год, по прошествии двух лет, на следующий день после, на 5-й день, сегодня/завтра/вчера (только если влияет на смысл, см. раздел 4.7)
	Date: period			Период, измеряемый в днях, неделях, месяцах и т. д., включая упоминания праздников	с 5 января по 10 февраля, Мезозойская Эра, Эпоха Возрождения, за сентябрь, за последние шесть лет, на майские праздники, с 15 ноября до Нового года
	Date: duration			Продолжительность, измеряемая в днях, неделях, годах и т. д. (как долго?)	в течение двух недель, три года, пять месяцев и два дня, за сутки, полдня
	<u>T</u> ime: absolute		Т	Явное время (когда? во сколько?)	15:30, полтретьего, пятнадцать минут одиннадцатого, три часа
Time	Time: relative			Относительное время, включая конечные предлоги (когда относительно другого времени?)	два часа назад, через минуту, за два часа до, по прошествии двух часов, в течение трех часов (напр., будет закончена работа, выполнен заказ и т.п.), на 56-й минуте
	Time: period			Временной период, измеряемый в секундах, минутах, часах	с двух до пяти, с 12-ти до 23-х, за последние два с половиной часа
	Time: duration			Продолжительность времени, измеряемая в секундах, минутах, часах (как долго по времени?)	в течение трех часов, пару минут, три часа, за полчаса
	Ordinal		3	Числа (и слова) для подсчета предметов (какой по счету?)	первый, второй, тысячный, следующий, предыдущий, (пред)последний
	Money		4	Денежная сумма, включая название валюты, в т. ч. "от до " (сколько денег?)	\$500, два евро, 100 рублей, один тенге, 300 динаров, 55 франков, 45 рублей 22 копейки, от 20 до 30 тыс. руб., от \$200 до \$300
	Percent		5	Процент (включая "%")	десять процентов, полпроцента, 99.9%, 147%, на 30.1% меньше
Numeric	Age		6	Возраст человека или предмета	25 лет, 20-летний, годовалый, новорожденный
	Quantity		8	Измерения, количество чего-либо с единицей измерения (сколько?)	два кило, два стакана, З ч. л., 670 км, полтора метра, 6.4 Вт, метровый, более трех человек, около пяти видов, ни разу, один из, дважды, вчетверо реже, однажды (в значении "однократно, один раз")
	Cardinal		0	Числа, не относящиеся к категориям выше	один, два, десять, миллион, 532, 12.331, 52 828, две трети, 1/3, 5:0
0.11		□ Plural □ Fiction [default]		Термины, не подпадающие под категории выше, включая научные термины, болезни, технологии и т. д.	4G, гигабайт, рибонуклеотид, минорные актиноиды, премия "Оскар", COVID-19, коронавирус, инсульт, ишемия миокарда
Oth	ner term	☑ Plural		Несколько разных терминов, объединенных в одну сущность	гепатит А и В, азотная и соляная кислоты
		☑ Fiction		Вымышленные термины	Татуин, Пандора, Скайнет, криптонит

2.3 Атрибуты типов сущностей

Некоторые сущности могут иметь один или несколько атрибутов из следующих:

- **Plural** два или более разных объекта, объединенных в одну именованную сущность.
- **Fiction** вымышленная сущность, как правило, относящаяся к литературе, кино, сериалам и др.
- Unconscious имена, которыми люди называют неразумные объекты. Доступно только для типа сущности Person.
- Department отдел внутри организации. Доступно только для типа сущности Organization.
- Media любые медиа-источники: издательства, социальные сети, телевизионные каналы и т. п. Доступно только для типа сущности Organization.
- Citizenship гражданство какой-либо страны. Доступно только для типа сущности Nationality.
- **Project** проекты, программы (государственные, научные, космические и т. п.). Доступно только для типа сущности **Product**.
- Trademark бренд, торговая марка продукта (не в значении Organization). Доступно только для типа сущности Product.



Рис. 15: Выбор атрибутов

По умолчанию ни один атрибут не выбран. Чтобы выбрать атрибут, после выбора типа сущности нажмите на один из атрибутов в разделе **Entity attributes**. В соответствующем поле появится флажок, и атрибут подсветится оранжевым (Рисунок 15).

2.4 Различия подтипов сущностей Time и Date

Time – сущность, измеряемая в часах, минутах, секундах и т. д.

Date – сущность, измеряемая в днях, неделях, месяцах, годах и т. д.

Сущности **Date** и **Time** – только конкретные дата и время. Слова "*недавно*, *скоро*, *в последнее время*" и т. п. не выделяются как сущность.

На Рисунке 16 наглядно изображены различия подтипов временных сущностей.

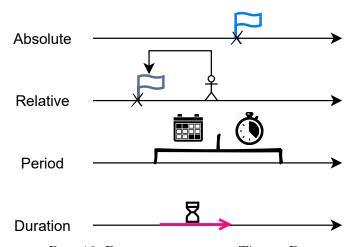


Рис. 16: Различия подтипов Time и Date

Absolute и Relative - всегда конкретное, точечное время. Period - период времени, который можно ограничить началом и концом. Duration - измеряемая продолжительность времени.

2.5 Некоторые правила вложенности и разделения сущностей

Сущности могут содержать в себе вложенные сущности, с которыми они связаны управлением 1 и их не разделяют предлоги или другие слова (см. "Вложенность" в Таблице 2).

¹Управление – вид подчинительной связи, при которой зависимое слово употребляется в том косвенном падеже, которого требует главное слово. В нашем случае – это, как правило, связь *существительное+существительное* (а точнее, *именная группа+именная группа*), например "[президент [Российской Федерации]]"

Если сущности разделены предлогом или другими словами, они выделяются раздельно, без вложенности (см. "Раздельные сущности" в Таблице 2).

В Таблице 2 приведены различия цельных, вложенных и раздельных сущностей.

Tuovinga 2. Tipimiepa genalam, antoniaman ii peogenalam ej aqueeten				
Одна сущность	Вложенность	Раздельные сущности		
[воронежский аэропорт]	[аэропорт [Воронежа]]	[аэропорт] в [Воронеже]		
[немецкий канцлер]	[канцлер [Германии]]	[канцлер] в [Германии]		
***	[Бурзянский район [Республики	[Бурзянский район] в [Республике		
	Башкортостан]]	Башкортостан]		
	[село Старосубхангулово	[село Старосубхангулово] в		
***	[Бурзянского района [Республики	[Бурзянском районе] в [Республике		
	Башкортостан]]]	Башкортостан]		
***	[ЦК [партии "Коммунисты	[ЦК] в [партии "Коммунисты		
	России"]]	России"]		
***	[бой [Головкина] против	между [Головкиным] и		
	[Альвареса]]	[Альваресом] состоялся [бой]		

Таблица 2: Примеры цельных, вложенных и раздельных сущностей

2.5.1 Про Facility, Event и Service

Одиночные сущности, относящиеся к категориям Facility, Event и Service (например, "аэропорт" и "бой" в Таблице 2, и упоминания сервисов "сайт", "форум" и т.п.), могут выделяться как именованная сущность, только если в этом же абзаце в пределах трех предложений справа и слева, включая центральное, есть уточнение (местоположение, год и т. п.), конкретизирующее эту одиночную сущность ("в Воронеже", "между Головкиным и Альваресом" в Таблице 2, для сервисов – упоминание организации, которой принадлежит сервис).

Примечание. Это правило не действует на одиночные упоминания, если в предыдущем контексте есть их полное название (например, [Международный аэропорт Воронеж] или [сайт Всемирной организации здравоохранения]) или если в этом абзаце в пределах трех предложений справа и слева, включая центральное предложение, нет уточнений/конкретизаторов этого упоминания.

2.5.2 Про Date в Facility и Event

Дата может быть вложенной в сущности Facility и Event, только если она является частью названия. Сравните:



В первом примере дата является частью названия, такой сущность можно увидеть на афишах и в СМИ. Во втором случае, дата – добавочная информация.

2.5.3 Про Event в Date: Absolute и Period

Cyщности Date: Absolute и Period могут включать в себя сущности Event, обозначающие праздники, например:



2.5.4 Про сочетания Family с Person и Person Property

В тексте будут встречаться разные комбинации сущности Family с Person Property и двумя вариантами $Person^2$.

На Рисунке 18 изображена правильная разметка разных сочетаний с сущностью Family.

При разметке нужно опираться на следующие правила:

- 1. Family атомарная сущность, т.е. в нее входит только термин, обозначающий родство (см. примеры в Таблице 1 и на Рисунке 18).
- 2. Family + Person (род. падеж) дополнительно объединяются в сущность Person, только если это выражение является подлежащим, действующим лицом в контексте (сравните варианты в примерах 1, 4, 5 на Рисунке 18).
- 3. Person (им. падеж) может включать сущность Family, только если между ними есть Person и/или Person Property в родительном падеже, поясняющие сущность Family (сравните примеры 2 vs. 3, 6, 7 на Рисунке 18). В противном случае, Person (им. падеж) не включает в себя Family (пример 2 на Рисунке 18).

Примечание. Конструкции с приложениями, как на Рисунке 17, не выделяются целиком как Person.

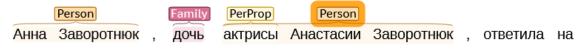


Рис. 17: Разметка Family в конструкции приложения.

 $^{^2}$ Именительный и родительный падежи Person при именительном падеже Family. Сравните: "сын Иван" vs. "сын Ивана".

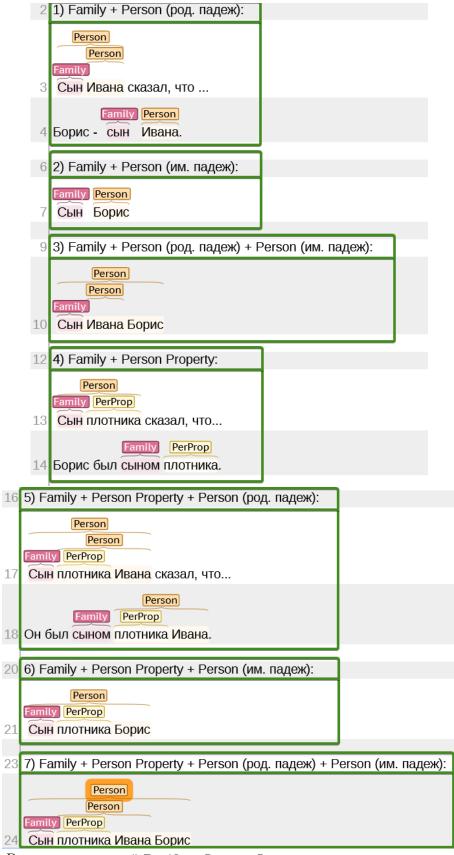


Рис. 18: Разметка сочетаний Family с Person Property и двумя вариантами Person

3 Разметка кореференции в brat

Все упоминания в **brat** отмечаются меткой X. На Рисунке 19 показаны выделенные упоминания в тексте.

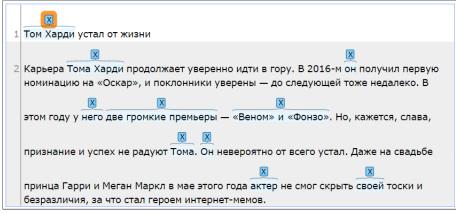


Рис. 19: Пример выделения упоминаний в brat

Все выделенные упоминания нужно попарно связать кореферентными связями. Всего в ru:corner четыре вида кореферентных связей: ANAPH, CATAPH, IDENT и APPOS. Подробную информацию об этих связях можно найти в Руководстве по разметке кореференции в ru:corner.

На Рисунке 20 показан пример текста с размеченными связями между упоминаниями.



Рис. 20: Пример кореферентной разметки в brat

Если в тексте нет референта, и все упоминания выражены местоимениями или нереферентными именными группами, следует отметить все упоминания такой кореферентной цепочки атрибутом **NoRef** (Рисунок 21).

Если у кореферентной группы указан референт в тексте, атрибут **NoRef** выбирать не нужно.



Рис. 21: Выбор атрибута **NoRef** для нереферентных упоминаний

Связь IDENT ненаправленная, связь ANAPH всегда направлена влево, связь CATAPH всегда направлена вправо, а связь APPOS может быть направлена и влево, и вправо.

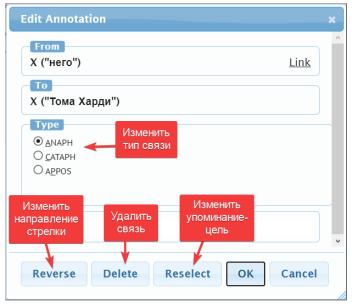


Рис. 22: Изменение или удаление связи между упоминаниями

Для выбора другой метки связи, выберите её из списка.

Примечание. Связь IDENT ненаправленная, ее нельзя переименовать в одну из направленных связей.

Чтобы поменять направление связи между упоминаниями, дважды кликните на нужную стрелку и в появившемся окне выбора связи нажмите **Reverse**.

Чтобы изменить упоминание-цель (упоминание, на которое указывает стрелка), дважды кликните на стрелку, нажмите **Reselect** и переместите освободившуюся стрелку на новое слово. Для удаления связи, дважды кликните на стрелку и нажмите **Delete** в окне выбора типа связей.

4 Отдельные случаи

В интерфейсе brat между всеми токенами³ для удобства разметки — три пробела. Каждое предложение отображается на новой строке, а между каждым абзацем есть пустая строка. Пример текста изображен на Рисунке 23.

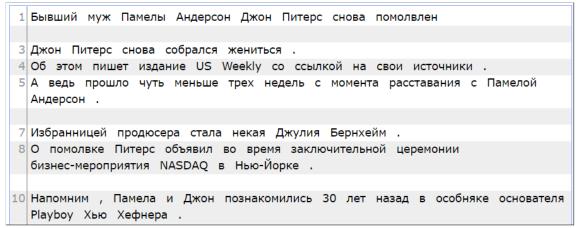


Рис. 23: Пример текста в интерфейсе brat

4.1 Уточняющие прилагательные

Прилагательные, уточняющие/конкретизирующие сущность (чаще всего они относятся к Person Property) входят в эту сущность, например:



Обычные качественные прилагательные, типа $\kappa pacusu \ddot{u}$, $\kappa pacusu \ddot{u$

4.2 Уточняющие именные группы

Уточняющие именные группы (существительное с зависимыми словами, если они есть) при именованных сущностях входят в эту сущность, например:

³Токены – отдельные слова и знаки пунктуации.

город Москва,	радиостанция Эхо Москвы,	издательство ЭКСМО,
американская авиак	омпания Delta Air Lines,	футбольный клуб "Зенит",
река Волга и т. п.		

4.3 Продукт, серия, уникальное название – как быть?

В тексте могут встретиться разные комбинации из упоминаний типа продукта, серии/производителя, уникального названия. В Таблице 3 приведены примеры, как следует выделять разные сочетания этих упоминаний.

Сочетание Как выделять Пример [самолеты Су-57] Product тип продукта [космические корабли серии "Союз"] (производитель или торговая & серия/производитель марка - Product:Trademark) [автомобиль [Форд]] [броненосец "Потёмкин"] тип продукта [американский космический Person:Unconscious & уникальное название корабль Орион] [тип продукта & серия] тип продукта [[Ледокол типа ЛК60Я] "Арктика"] название \rightarrow & серия/производитель [[Product] Person:Unconscious] & уникальное название тип продукта [тип продукта & название] & уникальное название cepuя] \rightarrow [[Ледокол "Арктика"] типа ЛК60Я] & серия/производитель [[Person:Unconscious] Product] целиком Person:Unconscious [Потемкин], [Орион] уникальное название [Катюша], [Су-57], [Т34] серия Product

Таблица 3: Разметка разных сочетаний Product и Person: Unconsious

4.4 Предлоги

Начальные предлоги могут входить в ряд типов сущностей:

- Все типы сущностей групп Date и Time
- Все типы сущностей группы Numeric, кроме Ordinal

Примеры предлогов в составе сущностей изображены на Рисунке 24.

Примечание. В конец сущности могут входить уточняющие предлоги, например: "[в трёх километрах <u>от</u>] $_{Quantity}$ деревни", "[за два часа до] $_{Time:Relative}$ начала", "[через два дня <u>после</u>] $_{Date:Relative}$ начала".

4.5 Знаки препинания

Знаки препинания входят в сущность, только если являются частью сущности (запятые в адресах, дефисы в номерах телефонов, двоеточия и т. п.).

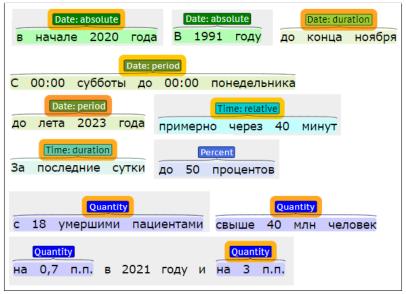


Рис. 24: Предлоги в составе сущностей

Конечные знаки препинания могут входить в сущность только если они являются частью названия объекта. Часто это восклицательные знаки, как, например, в *Mama Mia!* и *Кто боится Вирджинии Вульф?* (названия фильмов).

Запятые, точки, восклицательные, вопросительные и другие знаки препинания, не входящие в названия, не являются частью сущности (Рисунок 25).

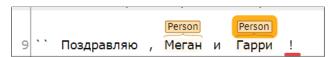


Рис. 25: Знаки препинания, как правило, не входят в сущность

4.6 Кавычки

В текстах начальные кавычки отображаются как ``, закрывающие кавычки

Кавычки входят в сущность, если обособляют названия объектов (Рисунок 26). Кавычки, обозначающие начало/конец прямой речи или цитаты в сущности не входят (Рисунок 27).



Рис. 26: Пример кавычек в названиях. Кавычки входят в сущность.



Рис. 27: Пример кавычек в прямой речи. Кавычки не входят в сущность.

4.7 Временные выражения с неопределенными границами

Выражение, обозначающее неопределенное время или временной промежуток, выделяется как сущность, только если оно несет смысловую нагрузку. Примеры таких выражений - ceйчac, cerodнa, saempa, evepa, eve

Тест на наличие смысловой нагрузки временного выражения. Уберите временное выражение из предложения. Если смысл предложения не изменился, временно выражение не отмечается как сущность (Таблица 4).

,	1 1 1	
Пример	Имеет смысловую нагрузку	Не имеет смысловой нагрузки
сейчас	<u>Сейчас</u> я еще студент, а завтра уже буду выпускником.	<u>Сейчас</u> я пекарь. = Я пекарь.
в настоящий момент	В настоящий момент суд принимает решение об оправдании, мы узнаем	$\frac{B}{7.5}$ мард человек. $=Ha$ Земле проживает $\frac{7.5}{7.5}$ мард человек. $=Ha$ Земле проживает

Таблица 4: Примеры временных выражений с неопределенными границами.

4.8 Одиночные именованные сущности и анафора

Анафоричные упоминания именованных сущностей, не имеющие смысла без антецедента, не выделяются как именованная сущность.

Например: Велорусская оппозиция раскрыла план действий при отказе Лукашенко покинуть пост. Если требования [оппозиции] не будут выполнены, последует ряд массовых забастовок.

В примере выше только выражение "Белорусская оппозиция" выделяется как именованная сущность. Отдельно упомянутое слово "оппозиция" не является именованной сущностью, так как без антецедента нельзя установить, какая именно это оппозиция.

При разметке кореференции выражение "*onnosuция*" следует выделить как анафор.

Исключением из правила является выражения "*столица*", "*граница*" и "*правительство*". Если в тексте подразумевается столица и Правительство <u>России</u>, "*столица*" размечается как именованная сущность GPE, "*граница*" – как Facility, а "*правительство*" – как Organization.

Кроме того, одиночные сущности Facility, Event и Service могут быть выделены как именованная сущность, если в рамках одного абзаца с ними есть конкретизирующее уточнение (Подробнее в Разделе 2.5).

Примечание. Одиночные слова, не указывающие на конкретный объект,

не выделяются как сущность. К таким, например, относятся *полиция*, *армия*, *власти*, *маркетплейсы*, *соцсети*, *ТВ*, *радио*.

4.9 Numeric: Quantity vs. Cardinal в случае эллипсиса

Единичные числа могут отмечаться как Quantity, если в тексте объект счета пропущен, но может быть восстановлен из контекста. На Рисунке 28 выделенное выражение можно восстановить до "умер 7071 <u>человек</u>".



Рис. 28: Пример единичного числа в роли Quantity

4.10 Выделение сущности, разбитой на две строки

Если в результате сегментации текста одна сущность оказалась на нескольких строках, необходимо сначала разметить часть сущности на первой строке, затем снова зайти в выбор типа сущности, нажать на Add Frag. и выделить оставшуюся часть сущности на второй строке (Рисунок 29).

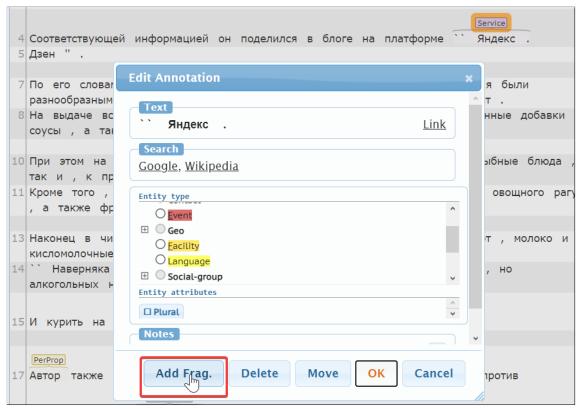


Рис. 29: Добавление фрагмента к сущности

После выделения фрагмента на второй строке, появится связь между двумя фрагментами (Рисунок 30).

```
4 Соответствующей информацией он поделился в блоге на платформе `` Яндекс .

5 Дзен " .
```

Рис. 30: Связь между фрагментами

Примечание. Если выделить разбитую на две строки сущность целиком, в интерфейсе появится ошибка (см. Раздел 4.11).

4.11 Возможные ошибки и предупреждения

Примечание. Некоторые критичные ошибки возникают из-за разметки в браузерах типа Chrome, Opera и др. Убедитесь, что вы установили и используете **Mozilla Firefox** для разметки в brat.

В некоторых случаях могут появляться ошибки или сообщения с предупреждениями. Возможные случаи:

• Пересекающиеся сущности. Пересекаться с другими сущностями могут только сущности Quantity. В остальных случаях при пересечении метки подсвечиваются красным (Рисунок 31). Необходимо переразметить сущности таким образом, чтобы они не пересекались.

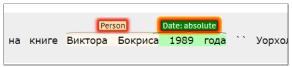


Рис. 31: Пример ошибки при пересечении сущностей.

Ошибки также возникают, если на пересечении вложенных сущностей оказываются лишние пробелы. Такие случаи тоже необходимо переразмтеить.



Рис. 32: Лишние пробелы на пересечении сущностей вызывают ошибки.

• Пробелы в начале сущности. Если в начало выделенной сущности попали пробелы, высветится предупреждающее сообщение (Рисунок 33). Чтобы предупреждение пропало, необходимо переразметить сущность (с

помощью **Move** или **Delete**), при выделении не включая лишние пробелы в начало.

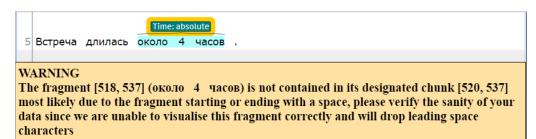


Рис. 33: Пример предупреждения при наличии пробелов в начале сущности.

Примечание. Лишние пробелы в конце сущностей будут удалены автоматически, они не вызывают сообщений с предупреждениями или ошибок.

• Случайное выделение части второй строки при выделении сущности вызовет серию ошибок, как изображено на Рисунке 34. Наиболее вероятная причина - разметка в нерекомендованном браузере. Удалить такую сущность самостоятельно и убрать ошибку не получится, обратитесь к администратору. В разделе 4.10 описано, как выделить сущность, разбитую на две строки, так, чтобы не возникало ошибок.



Рис. 34: Пример ошибки при выделении второй строки.

• Ошибка сегментации. Могут встречаться тексты, в которых цельные предложения разбиты на несколько строк (например, как на Рисунке 30). Если на границе строк одна сущность разбита на фрагменты, необходимо разметить ее, как описано в разделе 4.10. Редко: Если деление предложения не проходит по именованной сущности, в первой строке разбитого предложения отметьте любое слово, не являющееся сущностью, как !!!!INVALID DOCUMENT!!! и напишите комментарий "Ошибка сегментации". При этом остальной текст следует разметить как обычно.

A Changelog

11.01.2021

- 1. Обновлена Таблица 1: Добавлен атрибут Plural в тип сущности Event. Добавлены новые примеры в некоторые типы сущностей. Удалены противоречивые примеры из категории Person. Сущность Event перемещена выше в таблице и в интерфейсе brat.
- 2. Добавлен подраздел [DELETED] Выражения с упоминанием GPE, в т.ч. Таблица [DELETED] с примерами.
- 3. Добавлен раздел 4.7 Временные выражения с неопределенными границами, в т.ч. Таблица 4.

12.01.2021

- 1. Обновлена Таблица 1: Добавлен атрибут Plural в сущности GPE и Location. Удалены ошибочные примеры из категории Facility. В описание Facility добавлены "улицы, площади, переулки". Добавлены примеры в категорию Language, удалены противоречивые примеры.
- 2. Добавлен подраздел [UPGRADED TO SUBSECTION] *Различия подтипов сущностей Time и Date*, в т. ч. Рисунок 16 с наглядной диаграммой различий подтипов временных сущностей.
- 3. Добавлен раздел 4.8 Именованные сущности и анафора.

13.01.2021

- 1. Добавлен раздел **4.10** Выделение сущности, разбитой на две строки. Добавлена ссылка на этот раздел в пункте Случайное выделение... в разделе 4.11.
- 2. В разделе 4.11 добавлен пункт Ошибка сегментации.

14.01.2021

1. Обновлена Таблица 1. В описание категории Work of art добавлены "фильмы, ТВ шоу, сериалы". Добавлены уточняющие вопросы в описание некоторых категорий группы Numeric, отредактировано описание Quantity. В категорию Person добавлен атрибут Unconscious.

2. В разделе 2.3 добавлено описание нового атрибута Unconscious.

15-17.01.2021

1. Обновлена Таблица 1.

- В описание Event добавлено уточнение "не одиночные слова типа "концерт", "церемония" и т. д.".
- Изменен порядок сущностей в группе Numeric, обновлены их Hotkey.
- Добавлены типы сущностей Numeric: Age и Social-group: Family.
- В Quantity согласованы и добавлены примеры "дважды, вчетверо реже, ни разу, однажды (в значении "однократно, один раз")' и т. п.
- В Other group добавлены примеры "избиратели, бюджетники, поклонники, эксперты".
- В Event добавлены "президентские выборы в США".
- Исправлено описание категорий группы Date и Time (уточнение про кванты/изменения).
- В тип сущности Product добавлены атрибуты Project и Trademark.
- Чтобы уместить таблицу с новыми изменениями, уменьшен размер шрифта примеров.
- 2. Добавлен Раздел 2.2 *Вложенные и пересекающиеся сущности*, в т.ч. ряд скриншотов с примерами.
- 3. Добавлен подраздел 4.1 Уточняющие прилагательные.
- 4. В разделе 2.3 добавлены новые атрибуты Project и Trademark.
- 5. Удален раздел "Пояснения к некоторым типам сущностей". Ввиду разрешенной вложенности сущностей, он больше не актуален, вся необходимая информация по типам сущностей в колонке *Onucanue* Таблицы 1. Под-подаздел *Различия подтипов сущностей Time и Date* выделен в отдельный подраздел 2.4.
- 6. Удален ряд неактуальных или избыточных скриншотов.
- 7. **Расширен Раздел 4.8**. Добавлена информация о выделении или невыделении одиночных слов как именованные сущности по итогу обсуждения с fostroll.

8. Кроме вышеперечисленного, были добавлены незначитальные небольшие изменения в некоторые разделы в соответствии с новым допущением вложенности и подправлены примеры в Таблице 1.

19.01.2021

- 1. **Обновлена Таблица 1.** Добавлен Hotkey **Y** для сущности **Family**. В описание Facility добавлены $nap\kappa u$.
- 2. Переименован Раздел 1 Общая информация о разметке в brat.
- 3. В Раздел 1 добавлен абзац о необходимости установки и использования браузера Mozilla Firefox при разметке в brat. Выяснили, что браузеры на движке Chromium выделяют ненужный текст (от начала текста до начала выделения), если закончить выделение ниже или выше последнего символа. Это триггерит ошибки, которые можно убрать только вручную найдя и удалив ошибочную сущность, что может быть затратно по времени.

20.01.2021

1. **Обновлена Таблица 1.** В примеры **Family** добавлены слова "семья, род".

25.01.2021

- 1. Добавлен раздел 4.2 Уточняющие существительные. **TLDR**: слова типа "город, река, авиакомпания, радиостанция" входят в именованные сущности.
- 2. **Добавлен Рисунок 32** в раздел 4.11.
- 3. "**Рефакторинг**" раздела 4. Упрощение текста (выборочное, местами) без потери смысла.
- 4. **Обновлена Таблица 1.** В примеры Date: Absolute добавлено "в среду, 2 марта" как одна цельная сущность.

27.01.2021

1. Добавлен Раздел 2.5 Некоторые правила вложенности и разделения сущностей, в т.ч. Таблица 2 и правила по Facility-Event и Date.

- 2. **В Разделе 4.8 добавлена инфа про Facility и Event** с ссылкой на Раздел 2.5.
- 3. Обновлена Таблица 1.
 - В примеры Location добавлен "естественный спутник Земли".
 - В примеры Event добавлен "бой Хабиба и Коннора".
 - В примеры Organization добавлена "турецкая армия".
 - В описание "Date: Absolute" добавлено "включая упоминание праздников", в примеры добавлено "после майских праздников".
 - В описание "Date: Period" добавлено "включая упоминание праздников", в примеры добавлено "на новогодние праздники".

28.01.2021

1. **Изменен Раздел 2.5**. Правило "абзаца" для уточнений заменено на правило "окна в 3 предложения слева и справа". Добавлено правило про невыделение, если есть антецедент с полным названием.

29.01.2021

1. Обновлена Таблица 1

- В примеры Person: Unconscious добавлены броненосец "Потемкин", корабль "Сметливый", баркас "Fishizzle", "Союз МС-16", эсминец Джон Маккейн, в описание добавлены "корабли" и уточнение, что объект должен быть "уникальным".
- В примеры Person: Fiction добавлен "кот Матроскин".
- В описание Product добавлено "*техника*, серии водных/космических судов", в примеры добавлены танк Т34, космические корабли "Союз", Катюша (оружие).
- В Service добавлен новый атрибут Media с описанием и примерами. Примеры в категории дополнены.
- 2. Переименован Раздел 4.2: Уточняющие существительные \rightarrow Уточняющие именные группы.
- 3. **В Раздел 2.5 добавлено уточнение про Service** (аналогично с Facility и Event).

4. Добавлен Раздел 4.3 *Продукт*, серия, уникальное название – как быть?, в том числе, Таблица 3.

1.02.2021

1. Обновлена Таблица 1. В сущность Organization добавлен атрибут Media (уже был в интерфейсе).

2.02.2021

- 1. Добавлено уточнение про Event праздники в раздел 2.5.
- 2. В разделе 4.7 в ряд примеров добавлено "сегодня".

3.02.2021

- 1. Обновлена Таблица 1. В примеры Date:relative добавлены "на 5-й день, сегодня/завтра/вчера (только если влияет на смысл, см. раздел 4.7)". В примеры Time:relative добавлено "на 56-й минуте".
- 2. В разделе 24 добавлен пример "*через два дня после*". Добавила подчеркивание конечных предлогов.
- 3. В разделе 4.7 в ряд примеров добавлены "завтра, вчера".

4.02.2021

1. **Обновлена Таблица 1**. В примеры Money добавлены "*om 20 до 30 тыс. pyб., om \$200 до \$300*".

6.02.2021

- 1. Поменяла местами разделы $2.3, 2.4, 2.5 \rightarrow 2.3,1$
- 2. **В разделе 2.5** *Некоторые правила вложенности и разделения сущностей* пункты выделены в подразделы.
- 3. **Косметическая чистка текста**, в т.ч. теперь все названия сущностей в тексте, за некоторыми исключениями, выделены **таким шрифтом**.
- 4. Добавлен подраздел **2.5.4** Про сочетания Family с Person и Person Property, в т. ч. Рисунок 18. + Добавила приложение и Рисунок 17.

7.02.2021

1. Обновлена Таблица 1. В сущности Person property: Plural отредактировано описание, примеры заменены на "главы России, Азейбарджана и Армении". В Cardinal добавлен пример "5:0".